머신러닝응용 제13강

Association Rule Analysis

첨단공학부 김동하교수

제13강 Association Rule Analysis

1	연관성 분석의 개념에 대해 학습한다.
2	다양한 연관성 측도에 대해 학습한다.
3	Apriori 알고리즘에 대해 학습한다.

핵심 단어

- 연관규칙
- 지지도, 신뢰도, 향상도
- Apriori 알고리즘

13강. Association Rule Analysis

01. 연관규칙분석

1) 연관성 분석이란

- 데이터 안에 존재하는 항목간의 연관규칙 (association rule)을 발견하는 과정

- 연관 규칙
  - 상품을 구매하거나 서비스를 받는 등의 일련의 거래나 사건들의 연관성에 대한 규칙
  - 연관성 분석을 마케팅에서 손님의 장바구니에 들어있는 품목간의 관계를 분석
    - 장바구니분석 (market basket analysis).

1) 연관성 분석이란

- 슈퍼마켓에서 구입한 고객의 물건들이 담겨져 있는 장바구니 정보를 생각하자.

- 특정한 상품을 구입한 고객이 어떤 부류에 속하는지, 그들이 왜 그런 구매를 했는지를 알기 위해서 고객들이 구매한 상품에 대한 자료를 분석하는 것.
  - 이러한 분석을 통해 효율적인 매장진열, 패키지 상품의 개발, 교차판매전략 구사, 기획상품의 결정 등에 응용할 수 있다.

2) 연관성 분석의 응용

- 백화점이나 호텔에서 고객들이 다음에 원하는 서비스를 미리 알 수 있다.
- 신용카드, 대출 등의 은행서비스 내역으로 부터 특정한 서비스를 받을 가능성이 높은 고객의 탐지 가능.
- 의료보험금이나 상해보험금 청구가 특이한 경우 보험사기의 징조가 될 수 있고 추가적인 조사 필요.
- 환자의 의무기록에서 여러 치료가 같이 이루어진 경우 합병증 발생의 징후 탐지.

13강. Association Rule Analysis

02. 연관규칙

1) 연관규칙의 예

- 목요일 식료품 가게를 찾는 고객은 아기 기저귀와 맥주를 함께 구입하는 경향이 있다. (유용)

- 한 회사의 전자제품을 구매하던 고객은 전자제품을 살 때 같은 회사의 제품을 사는 경향이 있다. (상식적)

- 새로 연 건축 자재점에서는 변기덮개가 많이 팔린다. (유용하지 않음.)

1) 연관규칙의 예

- 첫 번째 규칙은 유용한 규칙으로 이를 이용하여 식료품 가게의 매출을 증가시킬 수 있다.

- 두 번째 규칙은 자명한 규칙으로, 대부분의 사람들이 이미 알고 있다. 자명한 규칙의 발견은 기존의 정보를 재 확인 하는 의미가 있다.

1) 연관규칙의 예

- 세 번째 규칙은 설명이 불가능한 규칙이며, 좀더 세밀한 조사가 필요하다.

- ✓ 규칙들 중에서 유용한 규칙을 발견하는 것은 분석자의 몫.

2) 동시구매표 작성

- 연관성분석은 하나 이상의 제품이나 서비스를 포함하는 거래 내역을 가지고 시작.

- 연관성 분석은 분석 목적상 제조업에서 생성된 제품이나 서비스를 품목 (item)이라 한다.

2) 동시구매표 작성

- 다음의 표는 5개 제품을 취급하는 편의점에 대한 5번의 거래 내역.

고객번호	품목
1	오렌지 주스, 사이다
2	우유, 오렌지 주스, 식기세척제
3	오렌지 주스, 세제
4	오렌지 주스, 세제, 사이다
5	식기세척제, 사이다

2) 동시구매표 작성

◆동시구매표 작성

	오렌지 주스	식기세척제	우유	사이다	세제
오렌지 주스	4	1	1	2	2
식기세척제	1	2	1	1	0
우유	1	1	1	0	0
사이다	2	1	0	3	1
세제	2	0	0	1	2

2) 동시구매표 작성

◆ 동시구매표 작성

- 동시구매표는 대칭 행렬의 모형을 보인다.
- 동시구매표를 보면 두 상품이 몇 번이나 함께 팔렸는지 알 수 있다.

2) 동시구매표 작성

동시구매표 작성

- 예를 들면, 사이다 행과 오렌지 주스 열이 교차하는 값을 살펴보면 두 상품이 두 번 같이 구매되었음을 알 수 있다.

- 동시구매표의 대각선 상의 자료 값은 바로 그 품목을 포함하는 총 거래 수를 나타낸다. 예를 들면, 오렌지 주스는 4번 구매되었다.

3) 연관 규칙의 조건

- 동시구매표로 부터 간단한 규칙 (예: 사이다를 구입하는 고객은 오렌지 주스를 산다)을 만들 수 있다.

- 두 품목을 함께 산 경우는 총 5번의 구매 중 2번 일어났으며 사이다를 산 3번의 구매 중 오렌지 주스가 2번 구매되었다.

3) 연관 규칙의 조건

- 연관 규칙은 “If A, then B”와 같은 형식으로 표현된다.
- 모든 “if-then” 규칙이 유용한 규칙이 아니다.
  - 어떤 조건을 이용하여 유용한 규칙을 추출할 수 있을까?

3) 연관 규칙의 조건

- 찾아진 규칙이 유용하게 사용되기 위해서는

  - 두 품목 (품목 A와 품목 B) 이 함께 구매한 경우의 수가 일정 수준 이상 이여야 하며,
    (일정 이상의 지지도)

  - 품목 A를 포함하는 거래 중 품목 B를 구입하는 경우의 수가 일정수준 이상 이여야 한다.
    (일정 이상의 신뢰도)

13강. Association Rule Analysis

03. 연관규칙분석의 측도

1) 지지도 (Support)

- 두 품목 A와 B의 지지도는 전체 거래항목 중 항목 A와 항목 B가 동시에 포함하는 거래의 비율

$$\text{지지도} = P(A \cap B) = \frac{A, B\text{가 동시에 포함된 거래수}}{\text{전체 거래수}}$$

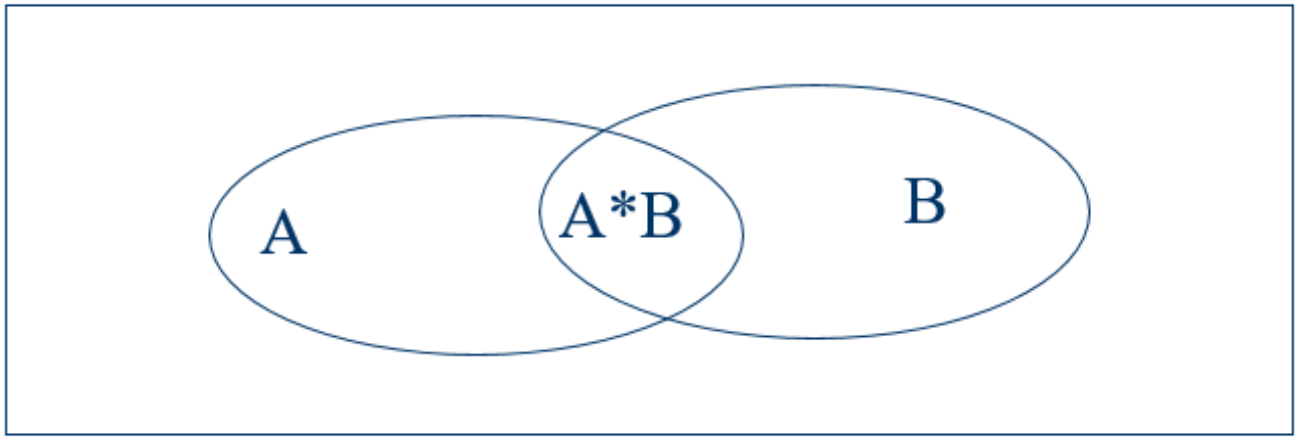

2) 신뢰도 (Confidence)

- 연관성 규칙 "If A, then B"의 신뢰도는

$$\text{신뢰도} = P(B|A) = \frac{A,B\text{가 동시에 포함된 거래수}}{\text{품목 } A\text{를 포함하는 거래수}}$$

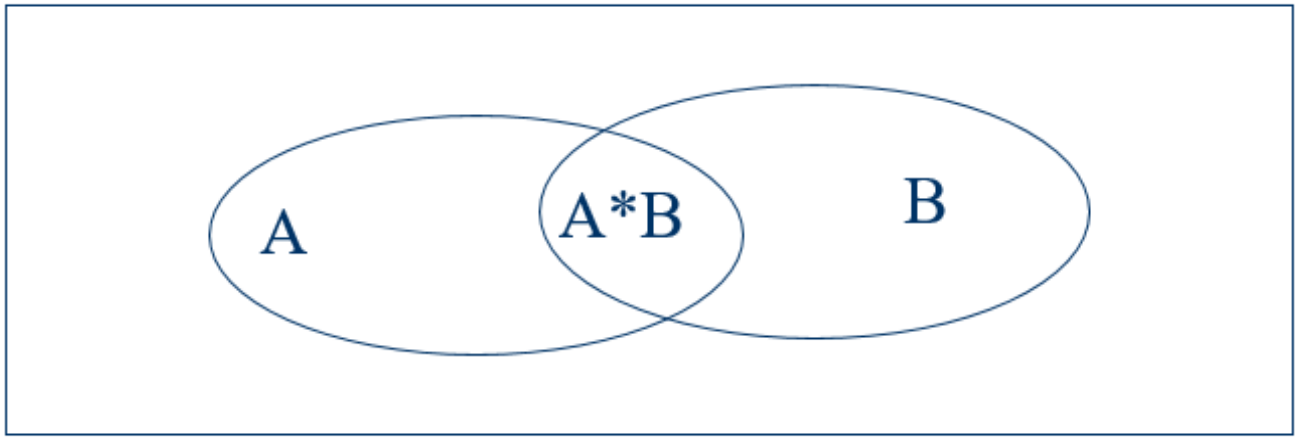

3) 예제

- 연관성 규칙 "오렌지 주스를 사면 사이다를 구매한다"의 지지도와 신뢰도를 구해보자.
  - 지지도=2/5
  - 신뢰도=2/4

고객번호	품목
1	오렌지 주스, 사이다
2	우유, 오렌지 주스, 식기세척제
3	오렌지 주스, 세제
4	오렌지 주스, 세제, 사이다
5	식기세척제, 사이다

3) 예제

- 연관성 규칙 "우유와 오렌지 주스를 사면 식기세척제를 산다"의 지지도와 신뢰도를 구하면
  - 지지도=1/5
  - 신뢰도=1/1

고객번호	품목
1	오렌지 주스, 사이다
2	우유, 오렌지 주스, 식기세척제
3	오렌지 주스, 세제
4	오렌지 주스, 세제, 사이다
5	식기세척제, 사이다

3) 예제

- 세 품목 A,B,C의 동시 거래 내역 (전체: 2,000회)

항목	거래의 수	항목	거래의 수
A	100	A+C	300
B	150	B+C	200
C	200	A+B+C	100
A+B	400	추가 안함	550

3) 예제

각 품목의 조합에 대한 지지도

항목	품목이 포함된 총 거래의 수	확률	항목	품목이 포함된 총 거래의 수	확률
A	900	0.450	A+C	400	0.200
B	850	0.425	B+C	300	0.150
C	800	0.400	A+B+C	100	0.05
A+B	500	0.250			

3) 예제

◆ 모든 연관성 규칙에 대한 신뢰도

규칙	P(A*B)	P(A)	신뢰도
A B	25	45	0.556
B A	25	42.5	0.588
C B	15	40	0.375
B C	15	42.5	0.353
A C	25	45	0.556

규칙	P(A*B)	P(A)	신뢰도
C A	20	40	0.500
(A+B) C	5	25	0.200
(B+C) A	5	15	0.333
(A+C) B	5	20	0.250

3) 예제

- 3가지 품목을 포함하는 연관성 규칙 중 가장 높은 신뢰도를 갖는 규칙은

  “B,C를 구입하면 A도 구매한다.” (신뢰도 0.333)

3) 예제

- 그러나, 이 연관성 규칙 실질적으로 의미 있는 규칙이 아닐 수도 있다.
  - 전체 거래에서 품목 {B,C}의 거래가 일어날 가능성(지지도)는 0.15로 작기 때문.
- 지지도와 신뢰도를 함께 사용해야 함.

4) 향상도 (Lift)

- 연관성 규칙 "A이면 B이다." 의 향상도는 다음과 같이 정의된다:

$$\text{향상도} = \frac{\text{품목 A와 B를 포함하는 거래 수} * \text{전체 거래 수}}{\text{품목 A를 포함하는 거래 수} * \text{품목 B를 포함하는 거래 수}}$$

- 즉, 향상도는 품목 A가 주어지지 않았을 때의 품목 B의 확률 대비 품목 A가 주어졌을 때의 품목 B의 확률의 증가 비율 이다.

4) 향상도 (Lift)

- 품목 A와 품목 B의 구매가 상호 관련이 없다면 P(B|A)와 P(B)와 같게 되어 향상도가 1이 된다.

- 어떤 규칙의 향상도가 1보다 크면, 이 규칙은 결과를 예측하는데 있어서 우연적 기회 (random chance)보다 우수하다는 것을 의미한다.

- 1보다 작으면 이 규칙이 결과를 예측하는데 있어서 우연적 기회보다 나쁘다는 것을 의미한다.

13강. Association Rule Analysis

04. 연관성분석의 절차

1) Apriori 알고리즘

- 품목의 개수가 k가지이면 모든 가능한 품목 조합의 수는 2^k.
- k 가 아주 큰 경우에 이 모든 집합 중에 지지도가 높은 집합을 찾는 것은 현실적으로 불가능
- 최소지지도보다 큰 집합 (빈발품목집합, frequent item set)만을 대상으로 높은 지지도를 갖는 품목 집합을 찾음.

1) Apriori 알고리즘

- 최소지지도를 넘는 모든 빈발품목집합(frequent itemset)을 생성한다.

- 빈발품목집합에서 최소 신뢰도를 넘는 모든 규칙을 생성한다.

2) 빈발품목집합의 생성

- 개별 품목 중에서 최소 지지도를 넘는 모든 품목을 찾는다.
- 위에서 찾은 개별 품목만을 이용해서 최소 지지도를 넘는 2가지 품목 집합을 찾는다.
- 위의 두 단계에서 찾은 품목 집합을 결합하여 최소 지지도를 넘는 3가지 품목 집합을 찾는다.
- 이런 방법을 반복적으로 사용하여 최소지지도가 넘는 빈발 품목 집합들을 찾을 수가 있다.

3) 빈발품목집합의 생성 예제

- 최소 지지도가 30% 인 빈발품목집합을 생성하자.

거래	품목
1	F, K, N
2	E, F
3	E, S
4	E, F, N
5	C, E, F, K, N
6	C, K, N
7	C, K, N

3) 빈발품목집합의 생성 예제

- 각 품목 C, E, F, K, N, S의 빈도가 각각 3, 4, 4, 4, 5, 1이므로 지지도는0.3(7 transaction × 0.3 =2.1)을 넘는 빈발 품목 집합(여기서는1-빈발 품목 집합으로 표현)은

$$F_1 = \{C, E, F, K, N\}$$

3) 빈발품목집합의 생성 예제

- 1-빈발 품목 집합의 원소들로 구성된 가능한 2-품목 조합으로 이루어진 2-후보 품목 집합은

$$C_2 = \{\{C,E\},\{C,F\},\{C,K\},\{C,N\},\{E,F\},\{E,K\},\{E,N\},$$
$$\{F,K\},\{F,N\},\{K,N\}\}$$

3) 빈발품목집합의 생성 예제

- C_2의 각 품목 집합의 빈도는 1, 1, 3, 3, 3, 1, 2, 2, 3, 4이므로 최소지지도를 넘는 2-빈발 품목 집합은

$$F_2 = \{\{C, K\}, \{C, N\}, \{E, F\}, \{F, N\}, \{K, N\}\}$$

- 3-후보 품목 집합은 다음과 같다.

$$C_3 = \{\{C, K, N\}\}$$

  - $\{E, F, N\}$ 도 고려해볼 수 있으나, $\{E, F, N\} \notin F_2$ 이므로 포함될 수 없다.

3) 빈발품목집합의 생성 예제

- {C,K,N} 의 빈도는 3으로 최소 지지도를 넘고, 따라서 3-빈발 품목 집합은 다음과 같다.

$$F_3 = \{\{C, K, N\}\}$$

4) 연관규칙의 생성

- 빈발품목집합에 대하여 연관규칙을 생성하기 위해, 공집합을 제외한 빈발품목집합의 모든 부분 집합을 대상으로 신뢰도를 계산하고 주어진 최소 신뢰도를 넘는 연관규칙을 찾음.

- 예제에서 빈발품목집합 F_1, F_2, F_3 이 생성되면 모든 가능한 연관규칙을 생성한 후 정해진 최소 신뢰도를 넘는 연관규칙을 찾음.

13강. Association Rule Analysis

05. 연관성분석의 고려사항

1) 올바른 품목 선택

- 어떤 품목을 선택할 것이냐는 문제는 전적으로 분석의 목적에 달려있다.
  - 예를 들면, 대형 할인점에서는 술을 하나의 상위 품목으로 고려할 수 있다.
  - 그러나, 어떤 경우에는 술을 세분화 하여 술을 소주, 양주, 맥주, 포도주, 막걸리 등의 술의 종류로 선택 할 수 있다.
  - 더욱 세분화 하여 포도주를 적색포도주와 백색포도주로 분류할 수 있고, 또한, 제조사의 상호를 기반으로 하여 분류할 수도 있다.

1) 올바른 품목 선택

- 품목의 수를 줄이는 방법으로, 품목의 분류를 상위수준으로 일반화 한다. (모든 종류의 술을 하나의 품목으로 분석)
- 품목을 세분화 하면 결과의 활용성이 높아진다. 예를 들면, 특정한 상표의 술에 대한 정보는 그 회사의 미래 마케팅 전략에 사용될 수 있다.
- 일반적인 방법은, 일차단계에서 상위수준의 품목 분류를 이용하여 규칙을 찾은 후 이를 바탕으로 세분화된 품목으로 분석을 진행시켜 나간다.

2) 연관성분석의 장점

- 결과가 분명하다 (If-then 규칙)
- 거대 자료의 분석의 시작으로 적합하다.
- 변수의 개수가 많은 경우에 쉽게 사용될 수 있다.
- 계산이 용이하다.

3) 연관성분석의 단점

- 품목 수의 증가에 따라 계산량이 폭증한다.
- 자료의 속성에 제한이 있다.
  - 예를 들면, 구매자의 개인정보 중 나이 등의 연속형 변수를 사용할 수 없다.
- 거래가 드문 품목에 대한 정보를 찾기가 어렵다.

13강. Association Rule Analysis

06. Python을 이용한 실습

1) 데이터 설명

- Adult 데이터셋
  - 미국 Census Bureau의 Census Income 데이터베이스에서 추출한 설문조사 자료
  - 48,842명
  - 나이, 성별, 직업군, 교육 정도 등을 나타낸 15개의 변수 결과 포함

- Adult 데이터셋을 이용하여 연관성분석을 수행해보자.

2) 환경설정

◆필요한 패키지 불러오기

```
import pandas as pd
import os
from mlxtend.frequent_patterns import apriori, association_rules
from mlxtend.preprocessing import TransactionEncoder
```

3) 데이터 불러오기

◆데이터 불러오기

```
Adult_file = os.getcwd()+'/data/Adult.csv'
Adult_df = pd.read_csv(Adult_file).transpose()
```

4) 데이터 전처리

◆ Transaction 데이터 형태로 변환해주기.

```
Adult_list = []
for i in range(0,len(Adult_df.columns)):
    Adult_list.append(Adult_df[i].to_string().split(","))
```

```
oht = TransactionEncoder()
oht_ary = oht.fit(Adult_list).transform(Adult_list)
df = pd.DataFrame(oht_ary, columns=oht.columns_)
df.head()
```

4) 데이터 전처리

◆Transaction 데이터 형태로 변환해주기.

	...	age=Middle-aged	capital-gain=Low	capital-loss=None	edu...	educati...	educatio...	education...
0	False	True	True	True	False	False	True	False
1	False	True	True	True	False	False	False	False
2	False	True	True	True	False	False	False	False
3	False	True	True	True	False	False	False	False
4	False	True	True	True	False	False	False	False

5 rows × 180 columns

5) 연관성분석 수행

◆ 지지도가 0.4 이상인 연관규칙 찾기

```
frequent_itemsets = apriori(df, min_support=0.4, use_colnames=True)
frequent_itemsets
```

	support	itemsets
0	1.000000	(age=Middle-aged)
1	1.000000	(capital-gain=Low)
2	1.000000	(capital-loss=None)
3	1.000000	(education=Bachelors)

5) 연관성분석 수행

◆지지도가 0.4 이상이면서 신뢰도가 0.7 이상인 연관규칙 찾기.

```
rules = association_rules(frequent_itemsets, metric="confidence",
                          min_threshold=0.7)
rules
```

	antecedents	consequents
0	(age=Middle-aged)	(capital-gain=Low)
1	(capital-gain=Low)	(age=Middle-aged)
2	(capital-loss=None)	(age=Middle-aged)

5) 연관성분석 수행

◆ 앞에서 찾은 결과 중에서 신뢰도가 0.75 이상, 향상도 0.9 이상인 연관규칙 찾기.

```
rules[ (rules['confidence'] >= 0.75) &
       (rules['lift'] >= 0.9) ]
```

	antecedents	consequents
0	(age=Middle-aged)	(capital-gain=Low)
1	(capital-gain=Low)	(age=Middle-aged)
2	(capital-loss=None)	(age=Middle-aged)
3	(age=Middle-aged)	(capital-loss=None)

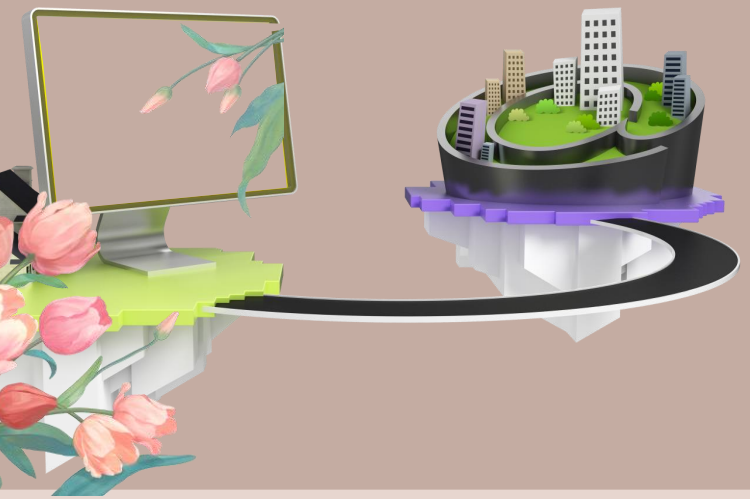

다음시간안내

제14강

Deep learning 1.